

**ΠΟΛΥΤΕΧΝΕΙΟ ΚΡΗΤΗΣ**

**Σχολή Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών**



**ΠΛΗ 402**

**ΘΕΩΡΙΑ ΥΠΟΛΟΓΙΣΜΟΥ**

**Εργασία Προγραμματισμού  
Λεκτική και Συντακτική Ανάλυση  
της Γλώσσας Προγραμματισμού MiniScript**

**Διδάσκων**

**Μιχαήλ Γ. Λαγουδάκης**

**Εργαστήριο**

**Γεώργιος Ανέστης**

**Εαρινό Εξάμηνο 2020**

Τελευταία ενημέρωση: 2020-04-29

## 1 Εισαγωγή

Η εργασία προγραμματισμού του μαθήματος «ΠΛΗ 402 – Θεωρία Υπολογισμού» έχει ως στόχο τη βαθύτερη κατανόηση της χρήσης και εφαρμογής θεωρητικών εργαλείων, όπως οι κανονικές εκφράσεις και οι γραμματικές χωρίς συμφραζόμενα, στο πρόβλημα της μεταγλώττισης (compilation) γλωσσών προγραμματισμού. Συγκεκριμένα, η εργασία αφορά στη σχεδίαση και υλοποίηση των αρχικών σταδίων ενός μεταγλωττιστή (compiler) για τη φανταστική γλώσσα προγραμματισμού **MiniScript**, η οποία περιγράφεται αναλυτικά παρακάτω.

Πιο συγκεκριμένα, θα δημιουργηθεί ένας **source-to-source compiler** (trans-compiler ή transpiler), δηλαδή ένας τύπος μεταγλωττιστή ο οποίος παίρνει ως είσοδο τον πηγαίο κώδικα ενός προγράμματος σε μια γλώσσα προγραμματισμού και παράγει τον ισοδύναμο πηγαίο κώδικα σε μια άλλη γλώσσα προγραμματισμού. Στην περίπτωση μας ο πηγαίος κώδικας εισόδου θα είναι γραμμένος στη φανταστική γλώσσα προγραμματισμού **MiniScript** και ο παραγόμενος κώδικας θα είναι στη γνωστή γλώσσα προγραμματισμού **C**.

Για την υλοποίηση της εργασίας θα χρησιμοποιήσετε τα εργαλεία **flex** και **bison**, τα οποία είναι διαθέσιμα ως ελεύθερο λογισμικό και τη γλώσσα **C**.

Η εργασία περιλαμβάνει δύο τμήματα:

- Υλοποίηση **λεκτικού αναλυτή** για τη γλώσσα **MiniScript** με χρήση **flex**
- Υλοποίηση **συντακτικού αναλυτή** για τη γλώσσα **MiniScript** με χρήση **bison**
  - Μετατροπή του κώδικα της **MiniScript** σε κώδικα **C** με χρήση ενεργειών του **bison**

### Παρατηρήσεις

- Η εργασία θα εκπονηθεί **ατομικά**. Η τυφλή αντιγραφή (plagiarism), ακόμη και από παλαιότερες εργασίες, μπορεί να διαπιστωθεί πολύ εύκολα και οδηγεί σε μηδενισμό.
- Για την εκπόνηση της εργασίας μπορούν να χρησιμοποιηθούν υπολογιστές του Μηχανογραφικού Κέντρου και προσωπικοί υπολογιστές. Τα εργαλεία flex και bison είναι διαθέσιμα σε οποιαδήποτε διανομή Linux.
- Η παράδοση της εργασίας θα γίνει **ηλεκτρονικά** μέσα από την ιστοσελίδα του μαθήματος στο [courses](#). Το παραδοτέο αρχείο τύπου archive (**.zip** ή **.tar**) θα πρέπει να εμπεριέχει όλα τα απαραίτητα αρχεία σύμφωνα με τις προδιαγραφές της εργασίας.
- Η εργασία πρέπει να παραδοθεί εντός της προθεσμίας. Εκπρόθεσμες εργασίες δεν γίνονται δεκτές. Μη παράδοση της εργασίας οδηγεί αυτόματα σε αποτυχία στο μάθημα.
- Η αξιολόγηση της εργασίας θα περιλαμβάνει **εξέταση καλής λειτουργίας** του παραδοτέου προγράμματος, σύμφωνα με τις προδιαγραφές, καθώς και **προφορική εξέταση** κατά την οποία θα πρέπει να εξηγήσετε κάθε τμήμα του κώδικα που έχετε παραδώσει και να απαντήσετε στις σχετικές ερωτήσεις. Η εξέταση θα γίνει σε ημέρες και ώρες που θα ανακοινωθούν.
- Το τμήμα της εργασίας που αφορά στη Λεκτική Ανάλυση αντιστοιχεί στο 30% του συνολικού βαθμού της εργασίας και το υπόλοιπο 70% αντιστοιχεί στη Συντακτική Ανάλυση.
- Υπενθύμιση: ο βαθμός της εργασίας θα πρέπει να είναι τουλάχιστον **40/100**. Συνεπώς, δεν αρκεί να παραδώσετε μόνο το τμήμα της Λεκτικής Ανάλυσης.

## 2 Η γλώσσα προγραμματισμού MiniScript

Η περιγραφή της γλώσσας **MiniScript** παρακάτω ακολουθεί τη γενική μορφή περιγραφής μιας γλώσσας προγραμματισμού. Πιθανότατα περιέχει και στοιχεία τα οποία δεν εντάσσονται στη λεκτική ή συντακτική ανάλυση. Είναι ευθύνη σας να αναγνωρίσετε αυτά τα στοιχεία και να τα αγνοήσετε κατά την ανάπτυξη του αναλυτή σας. Κάθε πρόγραμμα σε γλώσσα **MiniScript** είναι ένα σύνολο από *λεκτικές μονάδες*, οι οποίες είναι διατεταγμένες βάσει *συντακτικών κανόνων*, όπως περιγράφονται παρακάτω.

### 2.1 Λεκτικές μονάδες

Οι λεκτικές μονάδες της γλώσσας **MiniScript** χωρίζονται στις παρακάτω κατηγορίες:

- Τις **λέξεις κλειδιά** (*keywords*), οι οποίες είναι δεσμευμένες (*reserved*) και δεν μπορούν να χρησιμοποιηθούν ως αναγνωριστικά ή να επανωρισθούν, οι οποίες είναι οι παρακάτω:

<b>number</b>	<b>boolean</b>	<b>string</b>	<b>void</b>	<b>true</b>
<b>false</b>	<b>var</b>	<b>const</b>	<b>if</b>	<b>else</b>
<b>for</b>	<b>while</b>	<b>function</b>	<b>break</b>	<b>continue</b>
<b>not</b>	<b>and</b>	<b>or</b>	<b>return</b>	<b>null</b>
<b>start</b>				

Οι λέξεις κλειδιά είναι case-sensitive, δηλαδή δεν μπορείτε να χρησιμοποιήσετε κεφαλαία γράμματα γι' αυτές.

- Τα **αναγνωριστικά** (*identifiers*) που χρησιμοποιούνται για ονόματα μεταβλητών και συναρτήσεων και αποτελούνται από ένα πεζό ή κεφαλαίο γράμμα του λατινικού αλφαβήτου, ακολουθούμενο από μια σειρά μηδέν ή περισσότερων πεζών ή κεφαλαίων γραμμάτων, ψηφίων του δεκαδικού συστήματος ή χαρακτήρων υπογράμμισης (*underscore*). Τα αναγνωριστικά δεν πρέπει να συμπίπτουν με τις λέξεις κλειδιά.

Παραδείγματα: `x` `y1` `angle` `myValue` `Distance_02`

- Οι **αριθμητικές σταθερές** (*number constants*), που αποτελούνται από ένα ακέραιο μέρος, ένα κλασματικό μέρος και ένα προαιρετικό εκθετικό μέρος. Το ακέραιο μέρος αποτελείται από ένα ή περισσότερα ψηφία (του δεκαδικού συστήματος) χωρίς περιττά μηδενικά στην αρχή. Το κλασματικό μέρος αποτελείται από το χαρακτήρα της υποδιαστολής (`.`) ακολουθούμενο από ένα ή περισσότερα ψηφία του δεκαδικού συστήματος. Τέλος, το εκθετικό μέρος αποτελείται από το πεζό ή κεφαλαίο γράμμα `E`, ένα προαιρετικό πρόσημο `+` ή `-` και ένα ή περισσότερα ψηφία του δεκαδικού συστήματος χωρίς περιττά μηδενικά στην αρχή.

Παραδείγματα: `42` `42.4` `4.2e1` `0.420E+2` `42000.0e-3`

- Οι **λογικές σταθερές** (*boolean constants*), που είναι οι λέξεις-τιμές **true** και **false**.
- Οι **σταθερές συμβολοσειρές** (*constant strings*), που αποτελούνται από μια ακολουθία κοινών χαρακτήρων ή χαρακτήρων διαφυγής (*escape characters*) μέσα σε διπλά ή μονά εισαγωγικά. Κοινοί χαρακτήρες θεωρούνται η τελεία, το κόμμα, το κενό, οι χαρακτήρες **a-z**, **A-Z**, **0-9** και τα σύμβολα `-`, `+`, `*`, `/`, `:`, `_`, `$`, `!`, `#`, `@`, `&`, `~`, `^`, `(`, `)`. Οι χαρακτήρες διαφυγής ξεκινούν με το `\` (*backslash*) και είναι μόνο αυτοί που περιγράφονται στον εξής πίνακα.

Χαρακτήρας Διαφυγής	Περιγραφή
<code>\n</code>	χαρακτήρας αλλαγής γραμμής (line feed)
<code>\t</code>	χαρακτήρας στηλοθέτησης (tab)
<code>\r</code>	χαρακτήρας επιστροφής στην αρχή της γραμμής
<code>\\</code>	χαρακτήρας <code>\</code> ( <i>backslash</i> )
<code>\'</code>	χαρακτήρας <code>'</code> (μονό εισαγωγικό)
<code>\"</code>	χαρακτήρας <code>"</code> (διπλό εισαγωγικό)

Μια σταθερή συμβολοσειρά δεν μπορεί να εκτείνεται σε περισσότερες από μία γραμμές του αρχείου εισόδου. Ακολουθούν παραδείγματα έγκυρων συμβολοσειρών:

```
"M"    "\n"    '\ "'    "abc" 'def'  "Route 66"
'Hello world!\n'    "Item:\t\"Laser Printer\"\\nPrice:\t$142\n"
```

- Τους **τελεστές** (*operators*), οι οποίοι είναι οι παρακάτω:

αριθμητικοί τελεστές:	+	-	*	/	%	**
σχεσιακοί τελεστές:	==	!=	<	<=		
λογικοί τελεστές:	and	or	not			
τελεστές προσήμου:	+	-				
τελεστής ανάθεσης:	=					

Τελεστής	Περιγραφή
+, -, *, /	πρόσθεση, αφαίρεση, πολλαπλασιασμός, διαίρεση
%	υπόλοιπο διαίρεσης
**	Εκθεση σε δύναμη, π.χ. $2^{**}3$ , $a^{**}2$ , κ.ο.κ.
==	ίσο με (=)
<	μικρότερο από (<)
<=	μικρότερο από ή ίσο με ( $\leq$ )
!=	διάφορο από ( $\neq$ )
and	λογική σύζευξη
or	λογική διάζευξη
not	λογική άρνηση

- Τους **διαχωριστές** (*delimiters*), οι οποίοι είναι οι παρακάτω:

```
; ( ) , [ ] { } :
```

Εκτός από τις λεκτικές μονάδες που προαναφέρθηκαν, ένα πρόγραμμα **MiniScript** μπορεί επίσης να περιέχει και στοιχεία που αγνοούνται (δηλαδή αναγνωρίζονται, αλλά δεν γίνεται κάποια ανάλυση):

- Κενούς χαρακτήρες** (*white space*), δηλαδή ακολουθίες αποτελούμενες από κενά διαστήματα (*space*), χαρακτήρες στηλοθέτησης (*tab*), χαρακτήρες αλλαγής γραμμής (*line feed*) ή χαρακτήρες επιστροφής στην αρχή της γραμμής (*carriage return*).
- Σχόλια** (*comments*), τα οποία ξεκινούν με την ακολουθία χαρακτήρων `/*` και τερματίζονται με την πρώτη μετέπειτα εμφάνιση της ακολουθίας χαρακτήρων `*/`. Τα σχόλια δεν επιτρέπεται να είναι φωλιασμένα. Στο εσωτερικό τους επιτρέπεται η εμφάνιση οποιουδήποτε χαρακτήρα.
- Σχόλια γραμμής** (*line comments*), τα οποία ξεκινούν με την ακολουθία χαρακτήρων `//` και εκτείνονται ως το τέλος της τρέχουσας γραμμής.

## 2.2 Συντακτικοί κανόνες

Οι συντακτικοί κανόνες της γλώσσας **MiniScript** ορίζουν την ορθή σύνταξη των λεκτικών μονάδων της.

### i) Προγράμματα

Ενα πρόγραμμα **MiniScript** μπορεί να βρίσκεται μέσα σε ένα αρχείο με κατάληξη `.ms` και αποτελείται από τα παρακάτω συστατικά τα οποία παρατίθενται μ' αυτή τη σειρά και **διαχωρίζονται** μεταξύ τους με το διαχωριστικό `;` :

- Δηλώσεις σταθερών (προαιρετικά)
- Δηλώσεις μεταβλητών (προαιρετικά)
- Ορισμοί συναρτήσεων (προαιρετικά)

- Την κύρια δομική μονάδα η οποία είναι η συνάρτηση **start**, η οποία δεν λαμβάνει ορίσματα και θεωρείται ότι δεν επιστρέφει κάποια τιμή (τύπος επιστροφής **void**). Αυτή η συνάρτηση είναι το σημείο εκκίνησης για την εκτέλεση του προγράμματος και είναι της μορφής:

```
function start() : void {  
    σώμα της start  
}
```

Ενα απλό παράδειγμα έγκυρου αρχείου **.ms** είναι το παρακάτω:

```
function start() : void {  
    var x: number;  
    x = 1 + 2 + 3 + 4;  
    writeNumber(x);  
    return 0;  
}
```

## ii) Τύποι δεδομένων

Η γλώσσα **MiniScript** υποστηρίζει τέσσερις βασικούς τύπους δεδομένων (data types):

**number**: αριθμοί (ακέραιοι και πραγματικοί)

**string**: χαρακτήρες

**boolean**: λογικές τιμές

**void**: απουσία τιμής, χρησιμοποιείται ως ο τύπος επιστροφής συναρτήσεων που δεν επιστρέφουν τιμή

Η **MiniScript** υποστηρίζει επίσης μονοδιάστατους πίνακες αποτελούμενους από **n** στοιχεία τύπου **type** της μορφής:

- **identifier[n] : type**, όπου το μέγεθος του πίνακα **n** θα πρέπει να είναι ακέραια σταθερά με θετική τιμή και το **type** έγκυρος βασικός τύπος. Παράδειγμα: **listOfNums[10] : number**

## iii) Μεταβλητές

Οι δηλώσεις μεταβλητών ξεκινούν με τη λέξη κλειδί **var**. Ακολουθούν ένα ή περισσότερα αναγνωριστικά μεταβλητών χωρισμένα με κόμμα και, τέλος, ο διαχωριστής **:** ακολουθούμενος από έναν τύπο δεδομένων. Πολλαπλές συνεχόμενες δηλώσεις μεταβλητών διαχωρίζονται μεταξύ τους με το διαχωριστικό **,** και εντάσσονται υποχρεωτικά στο ίδιο **var** και στον ίδιο βασικό τύπο. Οι μεταβλητές μπορούν να αρχικοποιούνται με κάποια τιμή κατά τη δήλωσή τους με χρήση του τελεστή ανάθεσης **=**. Ακολουθεί ένα παράδειγμα δηλώσεων μεταβλητών:

```
var i, j = 10.5: number;  
var s1, s2: string;  
var n1: number;  
var x = 3.5, y: number;  
var s = "hello", ss: string;  
var test = false: boolean;
```

## iv) Σταθερές

Οι σταθερές δηλώνονται όπως και οι μεταβλητές, χρησιμοποιώντας τη λέξη κλειδί **const** αντί της **var**, με τη διαφορά ότι θα πρέπει υποχρεωτικά να τους δίνεται αρχική τιμή με χρήση του τελεστή ανάθεσης. Παράδειγμα:

```
const pi = 3.14: number;
```

## ν) Συναρτήσεις

Η συνάρτηση (function) είναι μια δομική μονάδα, η οποία αποτελείται από τα παρακάτω συστατικά, τα οποία παρατίθενται μ' αυτή τη σειρά:

- **function** όνομα συνάρτησης ( δηλώσεις παραμέτρων ) : τύπος επιστροφής {  
     δηλώσεις τοπικών μεταβλητών και σταθερών (προαιρετικά)  
     εντολές  
     **return** έκφραση (προαιρετικά)  
  }

Η δήλωση μιας συνάρτησης ξεκινά με τη λέξη κλειδί **function** ακολουθούμενη από το όνομα της συνάρτησης, ακολουθούν οι παράμετροί της μέσα σε παρενθέσεις, ο διαχωριστής **:** ακολουθούμενος από τον τύπο του επιστρεφόμενου αποτελέσματος και το σώμα της συνάρτησης μέσα σε αγκύλες **{** και **}**. Οι παρενθέσεις είναι υποχρεωτικές, ακόμη κι αν μια συνάρτηση δεν έχει παραμέτρους. Ο επιστρεφόμενος τύπος μπορεί να είναι και πίνακας με χρήση των συμβόλων **[]** πριν τον τύπο. Ο τύπος επιστροφής μπορεί να παραλειφθεί, εάν η συνάρτηση δεν επιστρέφει κάποια συγκεκριμένη τιμή. Αν η συνάρτηση δεν περιέχει εντολή **return** ή η εντολή **return** δεν επιστρέφει κάποια τιμή, τότε θεωρείται ότι η τιμή επιστροφής είναι **void**. Ακολουθούν παραδείγματα ορισμού έγκυρων συναρτήσεων:

```
function f1(b: number, e: number) : number { return b ** e; }
function f2(s[]: string) : number { return 100; }
function f3(x[]: number) : [] number { x[2] = 2 * x[4]; return x; }
```

Μια συνάρτηση στο σώμα της περιέχει δηλώσεις (προαιρετικά) τοπικών μεταβλητών, σταθερών και τις εντολές της.

Η **MiniScript** υποστηρίζει ένα σύνολο προκαθορισμένων συναρτήσεων, οι οποίες βρίσκονται στη διάθεση του προγραμματιστή για χρήση οπουδήποτε μέσα στο πρόγραμμα. Παρακάτω, δίνονται οι επικεφαλίδες τους:

```
function readString(): string
function readNumber(): number
function writeString(s: string)
function writeNumber(n: number)
```

## vi) Εκφράσεις

Οι εκφράσεις (expressions) είναι ίσως το πιο σημαντικό κομμάτι μιας γλώσσας προγραμματισμού. Οι βασικές μορφές εκφράσεων είναι οι σταθερές, οι μεταβλητές οποιουδήποτε τύπου και οι κλήσεις συναρτήσεων. Σύνθετες μορφές εκφράσεων προκύπτουν με τη χρήση τελεστών και παρενθέσεων.

Οι τελεστές της **MiniScript** διακρίνονται σε τελεστές με ένα όρισμα και τελεστές με δύο ορίσματα. Από τους πρώτους, ορισμένοι γράφονται πριν το όρισμα (prefix) και ορισμένοι μετά (postfix), ενώ οι δεύτεροι γράφονται πάντα μεταξύ των ορισμάτων (infix). Η αποτίμηση των ορισμάτων των τελεστών με δύο ορίσματα γίνεται από αριστερά προς τα δεξιά. Στον παρακάτω πίνακα ορίζεται η προτεραιότητα και η προσεταιριστικότητα των τελεστών της **MiniScript**. Προηγούνται οι τελεστές που εμφανίζονται πιο ψηλά στον πίνακα. Όσοι τελεστές βρίσκονται στην ίδια γραμμή έχουν την ίδια προτεραιότητα. Σημειώστε ότι μπορούν να χρησιμοποιηθούν παρενθέσεις σε μια έκφραση για να δηλωθεί η επιθυμητή προτεραιότητα.

Τελεστές	Περιγραφή	Ορίσματα	Θέση, Προσεταιριστικότητα
<b>not</b>	Τελεστής λογικής άρνησης	1	prefix, δεξιά
<b>+</b> <b>-</b>	Τελεστές προσήμου	1	prefix, δεξιά
<b>**</b>	Υψωση σε δύναμη	2	infix, δεξιά
<b>*</b> <b>/</b> <b>%</b>	Τελεστές με παράγοντες	2	infix, αριστερή
<b>+</b> <b>-</b>	Τελεστές με όρους	2	infix, αριστερή

<code>==</code> <code>!=</code> <code>&lt;</code> <code>&lt;=</code>	Σχεταιικοί τελεστές	2	infix, αριστερή
<code>and</code>	Λογική σύζευξη	2	infix, αριστερή
<code>or</code>	Λογική διάζευξη	2	infix, αριστερή

Ακολουθούν παραδείγματα σωστών εκφράσεων:

```

-a                -- αντίθετος της μεταβλητής a
a + b * (b / a)   -- αριθμητική έκφραση
4 + 50.0*x / 2.45 -- αριθμητική έκφραση
(a+1) % cube(b+3) -- αριθμητική έκφραση με κλήση συνάρτησης
(a <= b) and (d <= c) -- τελεστές λογικοί με σχεσιακούς
(c+a) != (2*d)    -- τελεστές αριθμητικοί με σχεσιακούς
a + b[(k+1)*2]    -- αριθμητική έκφραση με πίνακα

```

## vii) Εντολές

Οι εντολές (statements) που υποστηρίζει η γλώσσα **MiniScript** είναι οι ακόλουθες (όλες οι εντολές, εκτός της σύνθετης, θεωρούνται απλές):

- Η σύνθετη εντολή, που αποτελείται από μια (μη κενή) ακολουθία απλών εντολών που οριοθετείται από τους διαχωριστές { και }.
- Η εντολή ανάθεσης **v = expr**, όπου **v** είναι μία μεταβλητή και **expr** μια έκφραση.
- Η εντολή ελέγχου **if (expr) stmt<sub>1</sub> else stmt<sub>2</sub>**. Το τμήμα **else** είναι προαιρετικό. Το **expr** είναι μια έκφραση, ενώ τα **stmt<sub>1</sub>** και **stmt<sub>2</sub>** είναι απλές ή σύνθετες εντολές.
- Η εντολή επανάληψης **for (stmt<sub>1</sub> ; expr ; stmt<sub>2</sub>) stmt**, όπου τα **stmt<sub>1</sub>**, **stmt<sub>2</sub>** είναι απλές εντολές ανάθεσης που εκτελούνται πριν την έναρξη και σε κάθε επανάληψη αντίστοιχα, η **expr** είναι προαιρετική έκφραση που ελέγχεται/υπολογίζεται πριν από κάθε επανάληψη και το **stmt** είναι απλή ή σύνθετη εντολή που εκτελείται σε κάθε επανάληψη.
- Η εντολή βρόχου **while (expr) stmt**. Το **expr** είναι μια έκφραση και το **stmt** είναι μία απλή ή σύνθετη εντολή.
- Η εντολή διακοπής **break** που προκαλεί την άμεση έξοδο από τον πιο εσωτερικό βρόχο.
- Η εντολή συνέχισης **continue** που προκαλεί τη διακοπή της τρέχουσας επανάληψης και την έναρξη της επόμενης επανάληψης του βρόχου μέσα στον οποίο βρίσκεται.
- Η εντολή επιστροφής **return** ή **return expr**, που τερματίζει (πιθανά, πρόωρα) την εκτέλεση της συνάρτησης στην οποία βρίσκεται και επιστρέφει, όπου **expr** είναι μια (προαιρετική) έκφραση.
- Η εντολή κλήσης μιας συνάρτησης **f(expr<sub>1</sub>, ..., expr<sub>n</sub>)**, όπου **f** είναι το όνομα της συνάρτησης και **expr<sub>1</sub>, ..., expr<sub>n</sub>** είναι εκφράσεις που αντιστοιχούν στα δηλωθέντα ορίσματα της συνάρτησης.

Κάθε εντολή (απλή ή σύνθετη) της γλώσσας **MiniScript** τερματίζεται με το διαχωριστικό **;** στο σημείο όπου εμφανίζεται, ανεξάρτητα από το αν ακολουθούν άλλες εντολές ή όχι. Εξαιρούνται οι εντολές **if**, **for**, **while** και οι δύο εντολές ανάθεσης στις παρενθέσεις της εντολής **for**.

## 2.3 Αντιστοίχιση από την MiniScript στη C99

Η C99 είναι η αναθεώρηση του standard της γλώσσας **C** που έγινε το 1999. Στην αναθεώρηση αυτή προστέθηκαν διάφορες χρησιμότητες επεκτάσεις στην κάπως παλιά **C89**. Δείτε το αντίστοιχο άρθρο της Wikipedia για παραπάνω λεπτομέρειες. Καθώς η **C99** είναι μια πλούσια γλώσσα, είναι ιδιαίτερα εύκολο να αντιστοιχίσει κανείς προγράμματα της **MiniScript** σε προγράμματα της **C99**. Τις λεπτομέρειες της απεικόνισης αυτής θα περιγράψουμε στη συνέχεια.

### 2.3.1 Αντιστοίχιση τύπων και σταθερών

Οι τύποι της **MiniScript** αντιστοιχίζονται με τους τύπους της **C99** με βάση τον παρακάτω πίνακα:

Τύπος της MiniScript	Αντιστοιχημένος τύπος της C99
<code>number</code>	<code>double</code>
<code>boolean</code>	<code>int</code>
<code>string</code>	<code>char*</code>
<code>void</code>	<code>void</code>
<code>array[n] : T</code>	<code>T array[n]</code>
<code>[] : T</code>	<code>T*</code>
<code>function func(a1: T1, ... ak: Tk) : type</code>	<code>type (*) func(T1 a1, ... Tk ak)</code>

όπου **T**, **T1**, ..., **Tk** είναι κάποιος τύπος της **MiniScript**.

Στη βάση του παραπάνω πίνακα αντιστοιχίζονται και οι σταθερές της **MiniScript** σε σταθερές της **C99**. Για παράδειγμα, οι `boolean` σταθερές της **MiniScript**, `true` και `false`, αντιστοιχίζονται σε ακέραιες τιμές.

### 2.3.2 Αντιστοίχιση δομικών μονάδων

Ενα πρόγραμμα της **MiniScript** περιλαμβάνει προαιρετικά δηλώσεις μεταβλητών, συναρτήσεων και υποχρεωτικά το τμήμα του κυρίως κώδικα, δηλαδή την ειδική συνάρτηση `start` και αντιστοιχεί σε ένα αρχείο `.c` που περιλαμβάνει, δηλώσεις καθολικών μεταβλητών, συναρτήσεων και την αρχική ρουτίνα `main()`.

Η αντιστοίχιση είναι ως εξής:

- Μια **MiniScript** μεταβλητή `foo` με τύπο **T**

```
var foo, bar: T;
```

αντιστοιχεί σε μεταβλητή με ίδιο όνομα και με τον αντιστοιχισμένο τύπο

```
T foo, bar;
```

- Μια συνάρτηση της **MiniScript** αντιστοιχεί σε συνάρτηση της **C99** με ίδιο όνομα και τους αντιστοιχισμένους τύπους παραμέτρων.

Συνάρτηση της MiniScript	Συνάρτηση της C99
<code>function foo(x1: T1, ..., xn: Tn): type</code>	<code>type foo(T1 x1, T2 x2, ..., Tn xn)</code>

- Οι εντολές προγράμματος αντιστοιχούνται με προφανή τρόπο.
- Οι κλήσεις βιβλιοθήκης θα μπορούσαν να υλοποιηθούν ως εξής:

Κλήση MiniScript	Συνάρτηση υλοποίησης σε C99
<code>readString(): string</code>	Χρησιμοποιείστε την υλοποίηση που σας δίνεται στο αρχείο <code>mslib.h</code>
<code>readNumber(): number</code>	
<code>writeString(s: string)</code>	
<code>writeNumber(n: number)</code>	



Οι προκαθορισμένες συναρτήσεις της **MiniScript** αντιμετωπίζονται όπως όλες οι άλλες συναρτήσεις. Φροντίστε κατά τη μετατροπή του πηγαίου κώδικα της **MiniScript** σε **C** να συμπεριλάβετε (**#include**) στον παραγόμενο **C** κώδικα το αρχείο **mslib.h** που σας δίνεται και περιέχει την υλοποίηση των προκαθορισμένων συναρτήσεων της **MiniScript** σε **C**.

### 3 Αναλυτική περιγραφή εργασίας

#### 3.1 Τα εργαλεία

Για να ολοκληρώσετε επιτυχώς την εργασία χρειάζεται να γνωρίζετε καλά προγραμματισμό σε **C**, **flex** και **bison**. Τα εργαλεία **flex** και **bison** έχουν αναπτυχθεί στα πλαίσια του προγράμματος GNU και μπορείτε να τα βρείτε σε όλους τους κόμβους του διαδικτύου που διαθέτουν λογισμικό GNU (π.χ. [www.gnu.org](http://www.gnu.org)). Περισσότερες πληροφορίες, εγχειρίδια και συνδέσμους για τα δύο αυτά εργαλεία θα βρείτε στην ιστοσελίδα του μαθήματος.

Στο λειτουργικό σύστημα Linux (οποιαδήποτε διανομή) τα εργαλεία αυτά είναι συνήθως ενσωματωμένα. Αν δεν είναι, μπορούν να εγκατασταθούν τα αντίστοιχα πακέτα πολύ εύκολα. Οι οδηγίες χρήσης που δίνονται παρακάτω για τα δύο εργαλεία έχουν δοκιμαστεί στη διανομή Linux Ubuntu, αλλά είναι πιθανόν να υπάρχουν μικροδιαφορές σε άλλες διανομές.

#### 3.2 Προσέγγιση της εργασίας

Για τη δική σας διευκόλυνση στην κατανόηση των εργαλείων που θα χρησιμοποιήσετε καθώς και του τρόπου με τον οποίο τα εργαλεία αυτά συνεργάζονται, προτείνεται η υλοποίηση της εργασίας σε δύο φάσεις.

- **1η φάση: Λεκτική Ανάλυση**

Το τελικό προϊόν αυτής της φάσης θα είναι ένας Λεκτικός Αναλυτής, δηλαδή ένα πρόγραμμα το οποίο θα παίρνει ως είσοδο ένα αρχείο με κάποιο πρόγραμμα της γλώσσας **MiniScript** και θα αναγνωρίζει τις λεκτικές μονάδες (tokens) στο αρχείο αυτό. Η έξοδος του θα είναι μία λίστα από τα tokens που διάβασε και ο χαρακτηρισμός τους. Για παράδειγμα, για είσοδο:

```
i = k + 2;
```

η έξοδος του προγράμματός σας θα πρέπει να είναι

```
token IDENTIFIER: i
token ASSIGN_OP:  =
token IDENTIFIER: k
token PLUS_OP:   +
token CONST_INT: 2
token SEMICOLON: ;
```

Σε περίπτωση μη αναγνωρίσιμης λεκτικής μονάδας θα πρέπει να τυπώνεται κάποιο κατάλληλο μήνυμα λάθους στην οθόνη και να τερματίζεται η λεκτική ανάλυση. Για παράδειγμα, για τη λανθασμένη είσοδο:

```
i = k ^ 2;
```

η έξοδος του προγράμματός σας θα πρέπει να είναι

```
token IDENTIFIER: i
token ASSIGN_OP:  =
token IDENTIFIER: k
```

```
Unrecognized token ^ in line 46: i = k ^ 2;
```

όπου 46 είναι ο αριθμός της γραμμής μέσα στο αρχείο εισόδου όπου βρίσκεται η συγκεκριμένη εντολή συμπεριλαμβανομένων των γραμμών σχολίων.

Για να φτιάξετε ένα Λεκτικό Αναλυτή θα χρησιμοποιήσετε το εργαλείο flex και τον compiler gcc. Δώστε `man flex` στη γραμμή εντολών για να δείτε το manual του flex ή ανατρέξτε στο PDF αρχείο που βρίσκεται στο courses. Τα

αρχεία με κώδικα flex έχουν προέκταση `.l`. Για να μεταγλωττίσετε και να τρέξετε τον κώδικά σας ακολουθήστε τις οδηγίες που δίνονται παρακάτω.

1. Γράψτε τον κώδικα flex σε ένα αρχείο με προέκταση `.l`, π.χ. `mylexer.l`.
2. Μεταγλωττίστε, γράφοντας `flex mylexer.l` στη γραμμή εντολών.
3. Δώστε `ls` για να δείτε το αρχείο `lex.yy.c` που παράγεται από τον flex.
4. Δημιουργήστε το εκτελέσιμο με `gcc -o mylexer lex.yy.c -lfl`
5. Αν δεν έχετε λάθη στο `mylexer.l`, παράγεται το εκτελέσιμο `mylexer`.
6. Εκτελέστε με `./mylexer < example.ms`, για είσοδο `example.ms`.

Κάθε φορά που αλλάζετε το `mylexer.l` θα πρέπει να κάνετε όλη τη διαδικασία:

```
flex mylexer.l
gcc -o mylexer lex.yy.c -lfl
./mylexer < example.ms
```

Επομένως, είναι καλή ιδέα να φτιάξετε ένα script ή ένα makefile για να κάνει όλα τα παραπάνω αυτόματα.

## • 2η φάση: Συντακτική Ανάλυση και Μετάφραση

Το τελικό προϊόν αυτής της φάσης θα είναι ένας Συντακτικός Αναλυτής και Μεταφραστής της **MiniScript** σε **C**, δηλαδή ένα πρόγραμμα το οποίο θα παίρνει ως είσοδο ένα αρχείο με κάποιο πρόγραμμα της γλώσσας **MiniScript** και θα αναγνωρίζει αν αυτό το πρόγραμμα ακολουθεί τους συντακτικούς κανόνες της **MiniScript**. Στην έξοδο θα παράγει το πρόγραμμα που αναγνώρισε, στη γλώσσα **C**, εφόσον το πρόγραμμα που δόθηκε είναι συντακτικά σωστό, διαφορετικά θα εμφανίζεται ο αριθμός γραμμής όπου διαγνώσθηκε το πρώτο λάθος, το περιεχόμενο της γραμμής με το λάθος και *προαιρετικά* ένα κατατοπιστικό μήνυμα διάγνωσης. Για παράδειγμα, για τη λανθασμένη είσοδο

```
...
i = k + 2 * ;
...
```

το πρόγραμμά σας θα πρέπει να τερματίζει με ένα από τα παρακάτω μηνύματα λάθους

**Syntax error in line 46: i = k + 2 \* ;**

**Syntax error in line 46: i = k + 2 \* ; (expression expected)**

όπου 46 είναι ο αριθμός της γραμμής μέσα στο αρχείο εισόδου όπου βρίσκεται η συγκεκριμένη εντολή συμπεριλαμβανομένων των γραμμών σχολίων.

Για να φτιάξετε ένα συντακτικό αναλυτή και μεταφραστή θα χρησιμοποιήσετε το εργαλείο bison και τον compiler gcc. Δώστε `man bison` για να δείτε το manual του bison. Τα αρχεία με κώδικα bison έχουν προέκταση `.y`. Για να μεταγλωττίσετε και να τρέξετε τον κώδικά σας ακολουθήστε τις οδηγίες που δίνονται παρακάτω.

1. Υποθέτουμε ότι έχετε ήδη έτοιμο το λεκτικό αναλυτή στο `mylexer.l`.
2. Γράψτε τον κώδικα bison σε αρχείο με προέκταση `.y`, π.χ. `myanalyzer.y`.
3. Για να ενώσετε το flex με το bison πρέπει να κάνετε τα εξής:
  - Βάλτε τα αρχεία `mylexer.l` και `myanalyzer.y` στο ίδιο directory.
  - Βγάλτε τη συνάρτηση `main` από το flex αρχείο και φτιάξτε μια `main` στο bison αρχείο. Για αρχή το μόνο που χρειάζεται να κάνει η καινούρια `main` είναι να καλεί μια φορά την μακροεντολή του bison `yyparse()`. Η `yyparse()` τρέχει επανειλημμένα την `yylex()` και προσπαθεί να αντιστοιχίσει κάθε token που επιστρέφει ο Λεκτικός Αναλυτής στη γραμματική που έχετε γράψει στο Συντακτικό Αναλυτή. Επιστρέφει 0 για επιτυχή τερματισμό και 1 για τερματισμό με συντακτικό σφάλμα.
  - Αφαιρέστε τα `defines` που είχατε κάνει για τα tokens στο flex ή σε κάποιο άλλο `.h` αρχείο. Αυτά θα δηλωθούν τώρα στο bison αρχείο ένα σε κάθε γραμμή με την εντολή `%token`. Όταν κάνετε `compile` το

`myanalyzer.y` δημιουργείται αυτόματα και ένα αρχείο με όνομα `myanalyzer.tab.h`. Το αρχείο αυτό θα πρέπει να το κάνετε `include` στο αρχείο `mylexer.l` και έτσι ο `flex` θα καταλαβαίνει τα ίδια `tokens` με τον `bison`.

4. Μεταγλωττίστε τον κώδικά σας με τις παρακάτω εντολές:

```
bison -d -v -r all myanalyzer.y
flex mylexer.l
gcc -o mycompiler lex.yy.c myanalyzer.tab.c -lfl
```

5. Καλέστε τον εκτελέσιμο `mycompiler` για είσοδο `test.ms` γράφοντας:

```
./mycompiler < test.ms
```

**Προσοχή!** Πρέπει πρώτα να κάνετε `compile` το `myanalyzer.y` και μετά το `mylexer.l` γιατί το `myanalyzer.tab.h` γίνεται `include` στο `mylexer.l`.

Το αρχείο κειμένου `myanalyzer.output` που παράγεται με το flag `-r all` θα σας βοηθήσει να εντοπίσετε πιθανά προβλήματα `shift/reduce` και `reduce/reduce`.

Κάθε φορά που αλλάζετε το `mylexer.l` και `myanalyzer.y` θα πρέπει να κάνετε όλη την διαδικασία. Είναι καλή ιδέα να φτιάξετε ένα `script` ή ένα `makefile` για όλα τα παραπάνω.

### 3.3 Παραδοτέα

Το παραδοτέο για την εργασία του μαθήματος θα περιέχει τα παρακάτω αρχεία (από τη 2η φάση):

- `mylexer.l`: Το αρχείο `flex`.
- `myanalyzer.y`: Το αρχείο `bison`.
- `mycompiler`: Το εκτελέσιμο αρχείο του αναλυτή σας.
- `correct1.ms`, `correct2.ms`: Δύο σωστά προγράμματα/παραδείγματα της **MiniScript**.
- `correct1.c`, `correct2.c`: Τα ισοδύναμα προγράμματα των δύο παραπάνω σε γλώσσα **C**.

Είναι δική σας ευθύνη να αναδείξετε τη δουλειά σας μέσα από αντιπροσωπευτικά προγράμματα.

### 3.4 Εξέταση

Κατά την εξέταση της εργασίας σας θα ελεγχθούν τα εξής:

- *Μεταγλώττιση των παραδοτέων προγραμμάτων και δημιουργία του εκτελέσιμου αναλυτή.* Ανεπιτυχής μεταγλώττιση σημαίνει ότι παραδώσατε πρόχειρη εργασία, καθώς δεν μπορεί να φανεί η λειτουργία της.
- *Επιτυχής δημιουργία του αναλυτή.* Ο βαθμός σας θα εξαρτηθεί από τον αριθμό των `shift-reduce` και `reduce-reduce conflicts` που εμφανίζονται κατά τη δημιουργία του αναλυτή σας.
- *Έλεγχος αναλυτή σε σωστά και λανθασμένα παραδείγματα προγραμμάτων **MiniScript**.* Θα ελεγχθούν σίγουρα αυτά του Παραρτήματος, αλλά και άλλα άγνωστα σ' εσάς παραδείγματα. Η καλή εκτέλεση τουλάχιστον των γνωστών παραδειγμάτων θεωρείται αυτονόητη.
- *Έλεγχος αναλυτή στα δικά σας παραδείγματα προγραμμάτων **MiniScript**.* Τέτοιοι έλεγχοι θα βοηθήσουν σε περίπτωση που θέλετε να αναδείξετε κάτι από τη δουλειά σας.
- *Ερωτήσεις σχετικά με την υλοποίηση.* Θα πρέπει να είστε σε θέση να εξηγήσετε θέματα σχεδιασμού, επιλογών και τρόπων υλοποίησης καθώς και κάθε τμήμα του κώδικα που έχετε δώσει και να απαντήσετε στις σχετικές ερωτήσεις. Επίσης, θα πρέπει να μπορείτε να κάνετε `compile` τον κώδικά σας μόνοι σας.

## 4 Επίλογος

Κλείνοντας θα θέλαμε να τονίσουμε ότι είναι σημαντικό να ακολουθείτε πιστά τις οδηγίες και να παραδώσετε αποτελέσματα σύμφωνα με τις προδιαγραφές που έχουν τεθεί. Αυτό είναι κάτι που πρέπει να τηρείτε ως μηχανικοί για να μπορέσετε στο μέλλον να εργάζεσθε συλλογικά σε μεγάλες ομάδες εργασίας, όπου η συνέπεια είναι το κλειδί για τη συνοχή και την επιτυχία του κάθε έργου.

Στη διάρκεια του εξαμήνου θα δοθούν διευκρινίσεις όπου χρειάζεται. Για ερωτήσεις μπορείτε να απευθύνεστε στον διδάσκοντα και στους υπεύθυνους εργαστηρίου του μαθήματος. Γενικές απορίες καλό είναι να συζητιούνται στο χώρο συζητήσεων του μαθήματος για να τις βλέπουν και οι συνάδελφοί σας.

**Καλή επιτυχία!**

## ΠΑΡΑΡΤΗΜΑ

### 5 Παραδείγματα προγραμμάτων της MiniScript

#### 5.1 Hello World!

```
/* My first MiniScript program. File: myprog.ms */  
const message = "Hello world!\n" : string;  
function start(): void {  
    writeString(message);  
}
```

Ζητούμενο αποτέλεσμα λεκτικής – συντακτικής ανάλυσης:

Token	KEYWORD_CONST:	const
Token	IDENTIFIER:	message
Token	ASSIGN_OP:	=
Token	CONST_STRING:	"Hello World!\n"
Token	COLON:	:
Token	KEYWORD_STRING:	string
Token	SEMICOLON:	;
Token	KEYWORD_FUNC:	function
Token	KEYWORD_START:	start
Token	LEFT_PARENTHESIS:	(
Token	RIGHT_PARENTHESIS:	)
Token	COLON:	:
Token	KEYWORD_VOID:	void
Token	LEFT_CURLY_BRACKET:	{
Token	IDENTIFIER:	writeString
Token	LEFT_PARENTHESIS:	(
Token	IDENTIFIER:	message
Token	RIGHT_PARENTHESIS:	)
Token	SEMICOLON:	;
Token	RIGHT_CURLY_BRACKET:	}

Your program is syntactically correct!

## 5.2 Συναρτήσεις της MiniScript

Παράδειγμα για την κατανόηση της σύνταξης συναρτήσεων στη γλώσσα **MiniScript**.

```
// File: useless.ms
// A piece of MiniScript code for demonstration purposes

const N = -100 : number;

var a, b: number;

function cube(i: number): number {
    return i*i*i;
}

function add(n: number, k: number): number {
    var j: number;

    j = (N-n) + cube(k);
    writeNumber(j);
    return j;
}

/* Here you can see some useless lines.
 * Just for testing the multi-line comments ...
 */
function start(): void {
    a = readNumber();
    b = readNumber();
    add(a, b); // Here you can see some dummy comments!
}
```

Το παραπάνω πρόγραμμα θα μπορούσε να ενδεικτικά να μεταφραστεί ως εξής:

```
#include <stdio.h>
/* MiniScript Library */
double readNumber() { double ret; scanf("%lf", &ret); return ret; }
void writeNumber(double n) { printf("%0.3lf",n); }

const double N = -100;

float a, b;

double cube(double i) {
    return i*i*i;
}

double add(double n, double k) {
    double j;

    j = (N-n) + cube(k);
    writeNumber(j);
    return j;
}

void main() {
    a = readNumber();
    b = readNumber();
    add(a, b);
}
```

Μπορεί να μεταφραστεί από τον compiler με την εντολή

```
gcc -std=c99 -Wall myprog.c
```

### 5.3 Πρώτοι αριθμοί

Το παρακάτω παράδειγμα προγράμματος στη γλώσσα **MiniScript** είναι ένα πρόγραμμα που υπολογίζει τους πρώτους αριθμούς μεταξύ **1** και **n**, όπου το **n** δίνεται από το χρήστη.

```
// File: prime.ms
var limit, num, counter: number;

function prime(n: number): boolean {
    var i: number;
    var result, isPrime: boolean;

    if (n < 0)
        result = prime(-n);
    else if (n < 2)
        result = false;
    else if (n == 2)
        result = true;
    else if (n % 2 == 0)
        result = false;
    else {
        i = 3;
        isPrime = true;
        while (isPrime and (i < n / 2)) {
            isPrime = n % i != 0;
            i = i + 2;
        };
        result = isPrime;
    };

    return result;
}

function start(): void {

    limit = readNumber();
    counter = 0;
    num = 2;

    while (num <= limit) {
        if (prime(num)) {
            counter = counter + 1;
            writeNumber(num);
            writeString(" ");
        };
        num = num + 1;
    };

    writeString("\n");
    writeNumber(counter);
}
```



## 5.4 Παράδειγμα με συντακτικό λάθος

```
1 /* My first MiniScript program */
2 const message = "Hello world!\n": string;
3
4 function start(): void {
5     writeString(message
6 }
```

Ζητούμενο αποτέλεσμα λεκτικής – συντακτικής ανάλυσης:

Token KEYWORD_CONST:	const
Token IDENTIFIER:	message
Token ASSIGN_OP:	=
Token CONST_STRING:	"Hello World!\n"
Token COLON:	:
Token KEYWORD_STRING:	string
Token SEMICOLON:	;
Token KEYWORD_FUNC:	function
Token KEYWORD_START:	start
Token LEFT_PARENTHESIS:	(
Token RIGHT_PARENTHESIS:	)
Token COLON:	:
Token KEYWORD_VOID:	void
Token LEFT_CURLY_BRACKET:	{
Token IDENTIFIER:	writeString
Token LEFT_PARENTHESIS:	(
Token IDENTIFIER:	message
Token RIGHT_CURLY_BRACKET:	}

  

Syntax error in line 5:	writeString(message
ή	
Syntax error in line 5:	writeString(message
(Missing parenthesis)	